

One Big Jump: выполненные проверки и новый запуск

Срез: 15.09.2026 01:39 по Москве. Все численные таблицы построены программой из метрик и журналов. Основные завершённые эксперименты сохранены; новые проверки находятся в отдельной ветке артефактов.

Выполнена совместная проверка очищенной Kimina, отдельной калибровки и начала формального доказательства. Проведён случайный аудит разметки и дополнительная проверка прямым компилятором Leap. Протокол нового P2 зафиксирован до новых ответов. Для DeepSeek и Goedel собран отдельный набор с проверенными эталонами; генерация поставлена в очередь. Расширение P5 начинается с отдельной калибровочной части.

Универсальная связь «максимальный скачок всегда означает ошибку» по-прежнему не установлена. Исправления измерений не превращают повторный анализ старых задач в независимое подтверждение. Новое воспроизведение предназначено именно для такой проверки.

Раздельная калибровка и формальное начало

В очищенной Kimina удалены сохранённые наблюдения после завершения уже верного доказательства. Для нового X0 берётся последний исходный токен на границе начала формального тела доказательства. Токен, захватывающий содержательный текст первой тактики, не используется как начало. Это явно отличается от исходного определения статьи, где X0 находится в конце промпта.

Модель	Трасс в парном сравнении	Нет формальной границы	Удалено конечных шагов
deepseek	2486	0	0
goedel	2381	0	0
kimina	2265	0	988

Внутри прежней калибровочной части задачи разделены на две непересекающиеся группы: одна обучает среднее и ковариацию, другая задаёт порог верхнего процентиля. Направления разбиения поменяны местами; проверены все заранее указанные значения shrinkage. Оценочные задачи не используются ни для преобразования, ни для порога.


Модель	Fit fold	Ложные срабатывания на верных шагах	Обнаружение ошибочного шага	Top1 скачок	Top1 surprisal
deepseek	0	0.83%	0.76%	24.43%	17.61%
deepseek	1	1.55%	2.27%	23.67%	17.61%
goedel	0	0.75%	3.12%	25.45%	13.17%
goedel	1	0.44%	4.02%	23.21%	13.17%
kimina	0	2.57%	17.59%	17.28%	12.04%
kimina	1	0.80%	6.79%	14.20%	12.04%

В таблице доли top1 имеют вес попыток. Ложные срабатывания измеряются на шагах целиком верных оценочных доказательств; обнаружение — на локализованном первом неверном шаге. Порог и argmax отвечают на разные вопросы. Низкая частота ложных срабатываний не означает высокой чувствительности.

Модель	Fit fold	Задач	Top1: скачок – surprisal, п.п.	95% интервал, п.п.
deepseek	0	122	-0.80	[-7.76; +6.09]
deepseek	1	122	+1.67	[-5.80; +9.13]

Модель	Fit fold	Задач	Top1: скачок – surprisal, п.п.	95% интервал, п.п.
goedel	0	122	+8.31	[+1.26; +15.47]
goedel	1	122	+6.37	[-0.66; +13.23]
kimina	0	94	+8.54	[+0.39; +16.80]
kimina	1	94	+4.01	[-3.84; +12.07]

Здесь каждой прежней задаче дан одинаковый вес, а преобразование зафиксировано. Интервалы номинальные и описательные: эти данные уже многократно анализировались, поэтому положительная граница не является новым подтверждением. У DeepSeek результат при таком взвешивании близок к нулю. Все варианты, включая противоположное разбиение и другие значения shrinkage, сохранены в полном metrics.json.



Обе перестановки калибровочных групп; очищенные данные, формальное начало, shrinkage из основной настройки. Разброс между точками показывает чувствительность к разбиению.

Случайный аудит Lean

Всего случайно отобрано и повторно проверено 133 ответов. Совпало 133 исходных категорий; точная локализация воспроизвелась в 36 выбранных случаях, для которых она ранее была установлена. Отбор выполнен без использования величины скачка или surprisal.

Модель	Проверено	Категории совпали	Верные: подтверждены Lean CLI	Разногласия CLI, кроме обрывов
deepseek	43	43	6/6	0
goedel	42	42	6/6	0
kimina	48	48	6/6	0

Отбор стратифицирован: отдельно проверены верные доказательства, ранняя и более поздняя локализованная ошибка, отсутствие надёжной локализации, незакрытые цели, обрыв генерации, ресурсные/контекстные исключения и ошибки формата. Малые категории включались полностью. Это не простая случайная выборка всех ответов, поэтому объединённую долю нельзя выдавать за несмещённую оценку частоты ошибок разметки.

Страта	DeepSeek	Goedel	Kimina
verified	6	6	6
localized_first	6	6	6
localized_later	6	6	6

Страта	DeepSeek	Goedel	Kimina
localization_unavailable	6	6	6
terminal_unsolved	1	0	6
truncated	6	6	6
resource_compatibility	6	6	6
format_other	6	6	6

Повтор через REPL проверяет воспроизводимость существующего конвейера. Прямой запуск Lean CLI дополнительно проверяет целое доказательство другим путём подачи исходника и аудит зависимостей теоремы. Эти проверки используют одну версию Lean и одно доверенное формальное утверждение; они не доказывают соответствие формализации неформальному тексту задачи.

deepseek: отдельный компилятор — {'source_excluded': 5, 'standalone_checked': 38}. Обрыв с целым допустимым сертификатом: 0.

goedel: отдельный компилятор — {'source_excluded': 7, 'standalone_checked': 35}. Обрыв с целым допустимым сертификатом: 0.

kimina: отдельный компилятор — {'source_excluded': 9, 'standalone_checked': 38, 'standalone_resource_timeout': 1}. Обрыв с целым допустимым сертификатом: 0.

Ошибка тактики означает, что конкретное применение тактики не прошло проверку. Незакрытая цель означает, что после доступного тела остаётся недоказанное обязательство; это не обязательно неверность последней выполненной тактики. В таких случаях условная привязка отказа к последней позиции не должна подменять надёжно воспроизведённую локализацию.

Обрыв по лимиту генерации сохраняется отдельным исходом. Ресурсный предел, несовместимость окружения, изменение утверждения моделью и ошибка формата тоже остаются отдельными категориями. Их нельзя автоматически объявлять математической ошибкой конкретного шага.

Новый набор для воспроизведения

Источник — исправленный ProofNet-Verified, зафиксированный git commit 160414332dc196583f6c37c310b420d2a3b07c58. Источник указывает Lean 4.28; эталон проверяется в фактическом закреплённом окружении проекта. Основное окружение не обновлялось.

В исходных эталонных файлах встречаются одновременно исходные и исправленные утверждения; встречается и повторяющееся имя задачи. Итоговый идентификатор включает номер записи. Проверяется не совпадение имени, а новое объявление с точным утверждением из JSON и с допустимыми зависимостями доказательства. Эталонные доказательства и неформальные решения не входят в промпты моделей.

Показатель	Значение
Кандидатов после проверки прежней генерации	364
Задач с прошедшим эталоном	236
Групп упражнений	221
Групп технического пилота	24
Групп независимой оценки	197
Исход проверки эталона	Задач
reference_incompatible	113

Исход проверки эталона	Задач
reference_verified	236
context_statement_mismatch	1
reference_unapproved_axiom	14

Модель	Всего новых попыток	Технический пилот	Независимая оценка
deepseek	944	104	840
goedel	944	104	840

Этот набор новый для истории генерации данного проекта. Отсутствие задач в предобучении моделей не установлено. Переход от miniF2F к учебниковым задачам меняет предметную область; новое исследование проверяет перенос результата, а не точное повторение исходного распределения задач.

Зафиксированный протокол подтверждения P2

Единица веса — группа независимого упражнения. Сначала усредняются пригодные попытки одной задачи, затем задачи внутри упражнения, затем сами группы. Подпункты одного упражнения не считаются отдельными независимыми наблюдениями.

Goedel: основной результат — средняя разность top1 между скачком и surprisal. DeepSeek: основной результат — точное совпадение максимума с ошибкой после первого наблюдения, когда первое приращение исключено, сверх позиционного контроля по учебнику и точной длине.

Для DeepSeek один представитель упражнения выбирается детерминированно по хешу до фильтрации позиции ошибки. Если у выбранного представителя отсутствует формальная граница, другой ответ вместо него не подбирается. Затем ошибки переставляются только внутри групп одинакового учебника и длины. Одиночные страты отдельно учитываются как несопоставимые.

В семействе два основных утверждения. Для Goedel требуется положительная нижняя граница двустороннего интервала уровня 97.50%. Для DeepSeek используется односторонний точный порог 0.025. При недостатке 20 независимых групп результат считается недостаточно определённым.

Границы не закливаются и не обрезаются искусственно: если соседнего шага нет, соответствующий сдвиг недоступен. Основное сравнение — $D=0$. Сдвиги и окно около ошибки остаются дополнительными проверками, для них указываются знаменатели и доступность границ.

Слой, температура, shrinkage, формальное начало, число попыток и правило остановки заданы до новых ответов. Преобразование берётся из фиксированного направления раздельной калибровки на старых задачах; лучший вариант по новой оценке не выбирается. Предусмотрено полное завершение запланированного набора, без остановки или расширения из-за промежуточного p-value.

Расширение контролируемого P5

Часть	Задач	Попыток
calibration	1000	2000
evaluation	500	1000

Сначала генерируется только калибровочная часть. Для каждой температуры независимо требуются не менее 20 верных задач для обучения преобразования и столько же для отдельного выбора порога, а также достаточное качество формата и подтверждение извлечения состояний. Оценочная часть автоматически допускается только после этого условия.

P5 остаётся контролируемым семейством цепочек `modus ponens` со случайными именами и порядком правил. Увеличение числа экземпляров не добавляет новых логических семейств. Синтаксическое ограничение формата не выбирает математически верный следующий шаг.

Предусмотрен прогноз успеха по длине: коэффициент оценивается на калибровочных задачах, качество прогноза проверяется на оценочных и сравнивается с постоянной вероятностью, также обученной на калибровке. Все назначенные попытки, включая неверный формат и обрывы, остаются в знаменателе. Подгонка зависимости от длины сама по себе не определяет экстремальный индекс, порог или тяжёлохвостый механизм.

Очередь, контроль и оставшиеся действия

Состояния планировщика ниже относятся к моменту 2026-09-14T22:39:54.435171+00:00. Численное время ожидания GPU не гарантируется: срок выдачи ресурса определяется планировщиком.

Этап	Статус	Заявки
calibration	COMPLETED	8467315
audit	COMPLETED	8467339_0, 8467339_1, 8467339_2
audit_cli	COMPLETED	8467357_0, 8467357_1, 8467357_2
references	COMPLETED	8467338_0, 8467338_1, 8467338_2, 8467338_3
p2_setup	COMPLETED	8467346
p5_calibration	PENDING (Priority)	8467324
p5_evaluation	NOT_SUBMITTED	
p2_generate	PENDING (Priority)	8467351
p2_verify	NOT_SUBMITTED	
p2_extract	NOT_SUBMITTED	
p2_analyze	NOT_SUBMITTED	
p5_analysis	NOT_SUBMITTED	
provenance_repair	COMPLETED	8467356
flow_checks	COMPLETED	8467358

Новый контроллер проверяет задания раз в 30 минут, запускает подготовленные зависимые этапы и может дважды продолжить сохранённый журнал после тайм-аута, отказа узла или вытеснения. Ошибка программы, схемы или целостности данных не обходится автоматически. Старые задания не отменяются. Сообщения из `сгop` в этот чат не подключены.

Следующие действия уже описаны в коде: завершить генерацию нового P2, выполнить Lean и точную сегментацию, извлечь состояния, применить зафиксированное преобразование и посчитать основные сравнения; для P5 — завершить калибровку, проверить допуск, затем получить независимую оценку. Результаты этих ещё не завершённых этапов в этом отчёте не заявляются.

Артефакты и воспроизведение

Корневая папка нового запуска на сервере:

`/beegfs/home/denis.rakhmankin/onebigjump/runs/followthrough_20260915_v1`. Протокол подтверждения: `/beegfs/home/denis.rakhmankin/onebigjump/audit/followthrough_20260915_v1/p2-confirmary-protocol.json`. Состояние контроля: `/beegfs/home/denis.rakhmankin/onebigjump/runs/followthrough_20260915_v1/flow/latest.json`.

В технических манифестах исправлены ссылки на временные пути REPL внутри контейнера: они заменены постоянными файлами с теми же наблюдаемыми SHA256. Исходные версии манифестов и журнал исправления сохранены; численные выходные файлы не менялись.

Код сохранён отдельно с хешами и отметкой dirty. Базовый commit не включает все сохранённые изменения, поэтому одного git checkout недостаточно. В компактном архиве есть отчёт, метрики, журналы выбранного аудита и исходники новых этапов; большие веса моделей и матрицы состояний в архив не включены.

Источник набора: <https://github.com/marcusm117/ProofNet-Verified> . Формальные определения проекта: docs/experimental_specification.md. Все экспериментальные числа происходят из перечисленных в манифесте файлов проекта.