

One Big Jump

Эксперименты, данные и промежуточные результаты

Срез: 16.09.2026 01:39 МСК.

Основная серия на miniF2F завершила сбор ответов и последующий анализ. Новая проверка переноса на ProofNet-Verified и расширенная калибровка логической дедукции были остановлены техническими сбоями; их продолжение восстановлено. Новых окончательных выводов по этим двум сериям пока нет.

1. Что мы проверяем

Модель сама генерирует формальное доказательство. Проверяющая система Lean устанавливает, принято ли доказательство и где воспроизводится первый отказ. На границах шагов мы измеряем изменение скрытого вектора модели. «Скачок» — величина такого изменения. Surprisal — насколько неожиданны для модели токены шага. Сравнение со surprisal проверяет, даёт ли геометрия скрытых состояний пользу сверх обычной неуверенности модели.

Хвост распределения описывает редкие большие значения. Калибровочная выборка служит для настройки измерения; отдельная оценочная выборка — для проверки его работы на новых задачах. Seed задаёт начальное состояние генератора случайных чисел.

P1 — различаются ли хвосты распределений скачков у верных и ошибочных решений. P2 — совпадает ли самый большой скачок с первым ошибочным шагом. P3 — можно ли надёжно оценить редкие превышения порога и их хвост. P4 — меняется ли хвостовой показатель при появлении обобщения у обучаемой модели. P5 — как меняется успешность логического вывода с длиной цепочки.

2. Уже полученные результаты

Модель	Ответы	Извлечены	
DeepSeek	6672	5143	
Goedel	6672	4873	
Kimina	6672	4947	

Модель	Верные в таблице	С ошибкой в таблице	P2: трассы / задачи
DeepSeek	3076	1858	528 / 122
Goedel	3140	1593	448 / 122
Kimina	3353	1456	324 / 94

«Ответы» — сохранённые попытки LLM. «Извлечены» — ответы, для которых получены результаты прохода модели. Научная таблица требует дополнительных условий пригодности. Последний столбец относится только к ошибочным оценочным трассам выбранной температуры; эти знаменатели не следует путать с общей долей решённых задач.

P2: доля ответов, в которых максимум точно попал в первую ошибку:

Модель	N / задачи	Jump top-1	Surprisal top-1	Равномерно
DeepSeek	528 / 122	24.4%	17.6%	9.7%
Goedel	448 / 122	25.2%	13.2%	8.7%
Kimina	324 / 94	17.3%	12.0%	8.7%

Это исходная выбранная ячейка завершённого анализа, а не результаты нового ProofNet. На старых данных преимущество Goedel над surprisal сохранялось после поправки при равном весе попыток; при равном весе задач вывод слабее. Последующие проверки с отдельной калибровкой и формальным началом доказательства сохраняют зависимость от выбранного разбиения. Старые данные уже использованы для выбора уточнений, поэтому требуется новое подтверждение.

P1 не дал устойчивого общего разделения верных и ошибочных решений. Для P3 выявлена проблема повторного использования одних калибровочных наблюдений при нормировке и выборе порога. Разделение этих задач заметно уменьшает ложные тревоги, но также снижает обнаружение ошибок. Для P4 обучение и обобщение получены, однако надёжного хвостового признака перехода не обнаружено. Совокупность результатов пока не подтверждает общий тяжёлохвостый механизм ошибки.

Случайный стратифицированный аудит повторил исходные категории всех выбранных ответов; отдельная проверка прямым компилятором также не выявила несогласия категорий вне ресурсных ограничений. Это повышает доверие к проверенным меткам, но не заменяет независимого воспроизведения научного эффекта.

3. Что сейчас продолжается

P2: DeepSeek и Goedel решают новый для истории генераций проекта набор ProofNet-Verified. В нём учебниковые задачи с формальными математическими утверждениями и предварительно проверенными эталонами; эталонные доказательства в запрос модели не передаются. Набор охватывает иную область задач, поэтому это проверка переноса. Отсутствие этих задач в предобучении моделей не установлено.

Модель	Часть	Сохранено / назначено
deepseek	Технический пилот	104 / 104
deepseek	Оценочная часть	241 / 840
goedel	Технический пилот	104 / 104
goedel	Оценочная часть	0 / 840

P5: Qwen решает искусственные цепочки правил вида «если А, то В; если В, то С», начиная с известного факта. Случайные имена и порядок правил меняются; формат ответа ограничен грамматикой, а логическую правильность проверяет отдельный алгоритм. Ограничение формата не подсказывает верный следующий вывод. Для отдельной калибровочной части сохранено 2000 ответов. Логически верны 359 ответов (17.95%); содержат ошибку вывода 1641. Ошибок формата нет. Состояния извлечены для всех ответов. Это калибровочные результаты, а не итоговая независимая проверка зависимости от длины. Оценочная часть допускается только после проверки формата, извлечения состояний и достаточного числа

независимо решённых калибровочных задач в каждой группе. Результат допуска: пройден; отдельная оценочная серия поставлена в очередь.

Восстановление P2 сохраняет исходные токены и явно учитывает ответы, для которых нельзя надёжно совместить текст с токенами. Такие ответы остаются в общем числе попыток, но не объявляются математическими ошибками. Уже записанные ответы не генерируются заново. Часть ответов не успела сохраниться при прежних сбоях; они повторяются с прежними назначенными seed, но побитовое воспроизведение утраченных ответов не гарантируется. Это ограничение нужно сохранить при интерпретации.

4. Что делать дальше для статьи

1. Завершить новый P2 по зафиксированному протоколу: проверить доказательства, извлечь состояния и оценить заранее выбранные сравнения на независимых группах задач. Не выбирать лучший слой, порог или способ взвешивания по новым ответам.
2. Завершить отдельную оценочную часть P5 после уже пройденного калибровочного допуска. Проверить прогноз успеха по длине на новых задачах и сравнить его с постоянной вероятностью успеха; учитывать все назначенные ответы.
3. Для P3 проверить точность интервалов и частоту ложных тревог при раздельном обучении преобразования и порога. Увеличение числа ответов само по себе ошибку калибровки не устраняет.
4. Формулировать статью вокруг реально поддержанных утверждений: ограниченного сигнала локализации, его переносимости и границ хвостового объяснения. Отрицательный результат P4 и нестабильность P1/P3 важны для проверки теории.

Валидность доказательств повышать нужно прежде всего независимыми задачами, корректными знаменателями, проверкой меток и заранее выбранными сравнениями. Простое увеличение числа попыток на старых задачах даёт меньше новой информации. Более широкие эксперименты разумно выбирать после результатов этой проверки переноса и калибровки.

Сводка проверяет контрольные суммы готовых отчётов и их метрик и фиксирует текущие журналы. Она не является новым пересчётом основных эффектов или повторной проверкой каждого доказательства.